Guía de Actividades **Práctico-Experimentales** Nro. 002

1. Datos Generales

Asignatura	Simulación
Integrantes	Bryan Gustavo Troya Velez
Ciclo	5
Unidad	U1: Introducción a la Simulación
Resultado de aprendizaje de la unidad	R1. Aplica análisis estadísticos de los datos de la Simulación para mejorar la calidad de los resultados, bajo los principios de solidaridad, transparencia, responsabilidad y honestidad.
Práctica Nro.	02
Título de la Práctica	Comparación de modelos determinísticos, estocásticos, discretos y continuos
Nombre del Docente	José O. Guamán Q.
Fecha	08 de Octubre de 2026 09 de Octubre 2026
Horario	Jueves 10h30 a 11h30 Viernes 07h30 a 09h30
Lugar	Aula
Tiempo planificado en el Sílabo	3

2. Objetivo(s) de la Práctica:

Diferenciar los principales paradigmas de simulación mediante la construcción de modelos computacionales.

1. Implementar un modelo determinístico y uno estocástico.
2. Comparar modelos discretos y continuos.
3. Analizar el efecto de la aleatoriedad sobre los resultados

3. Materiales y reactivos:

- Python 3.x}
- NumPy
- Matplotlib
- Visual Studio Code, PyCharm o Jupyter Notebook.

4. Equipos y herramientas

- Computadora con mínimo 4 GB de RAM.
- Procesador de doble núcleo o superior.
- Sistema operativo Linux o macOS.
- Conexión a Internet para instalar las herramientas

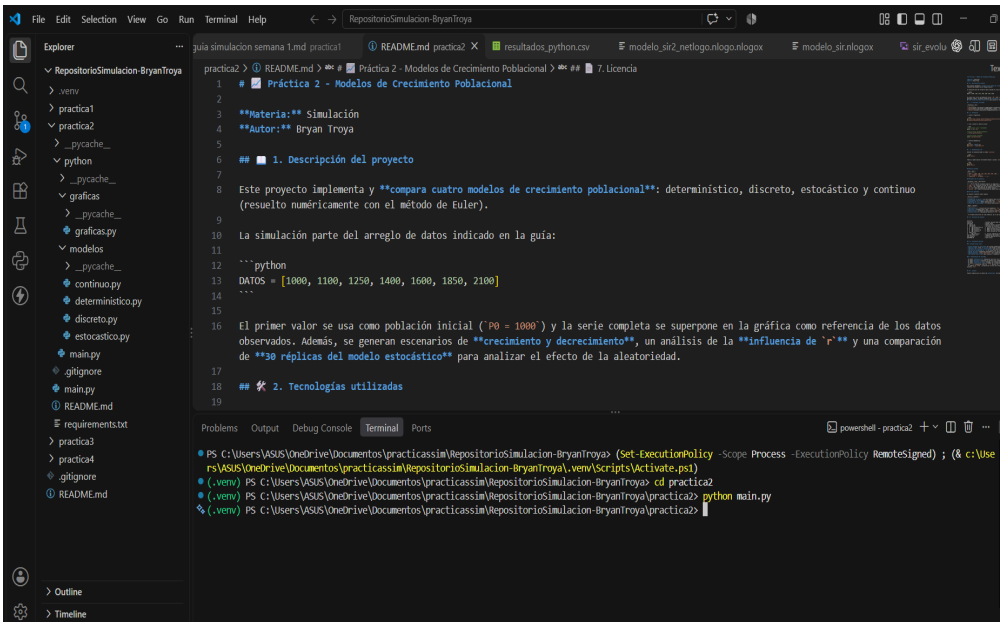
5. Procedimiento / Metodología

1. **Configuración del Entorno de Desarrollo:**
   Se preparó el entorno virtual en Python en Visual Studio Code / PyCharm, instalando las librerías especializadas NumPy, Matplotlib, Pandas y SciPy para el cómputo matricial, aproximación numérica y renderizado de curvas.
2. **Definición de Parámetros e Importación de Datos Base:**
   Se cargó el arreglo empírico de datos del sistema $datos = [1000, 1100, 1250, 1400, 1600, 1850, 2100]$, estableciendo la población inicial $P_0 = 1000$, y se configuraron los parámetros de tasa de crecimiento r, variabilidad σ y paso de integración Δt.
3. **Implementación de los Cuatro Paradigmas de Simulación:**
   - **Modelo Determinístico (Exponencial Continuo Exacto):** Se programó la función evaluativa $P(t) = P_0 e^{rt}$, generando una trayectoria analítica continua sin variabilidad aleatoria.
   - **Modelo Discreto (Ecuación en Diferencias Finita):** Se programó el modelo iterativo paso a paso $P_{t+1} = P_t + rP_t$, donde los cambios poblacionales ocurren en intervalos de tiempo fijos $\Delta t = 1$.
   - **Modelo Estocástico (Ecuación Diferencial Estocástica Discreta):** Se incorporó un término de ruido blanco gaussiano $\epsilon_t \sim N(0, \sigma^2)$ mediante la relación $P_{t+1} = P_t + rP_t + \epsilon_t$, introduciendo incertidumbre en cada paso temporal.
   - **Modelo Continuo (Aproximación Numérica por Método de Euler):** Se implementó la resolución de la ecuación diferencial ordinaria $\frac{dP}{dt} = rP$ utilizando pasos de integración pequeños Δt mediante la fórmula $P_{t+\Delta t} = P_t + \Delta t(rP_t)$.
4. **Generación de Gráficas Comparativas:**
   Se utilizó Matplotlib para trazar en un mismo plano cartesiano las curvas temporales de los cuatro modelos frente a los datos reales, personalizando títulos, ejes, cuadrículas y leyendas diferenciadas por tipo de línea y color.
5. **Evaluación de Escenarios y Análisis de Sensibilidad:**
   Se realizaron corridas variando la tasa r ($r > 0, r = 0, r < 0$), incrementando la varianza de ruido σ y reduciendo Δt, interpretando la convergencia matemática y las desviaciones de cada modelo.

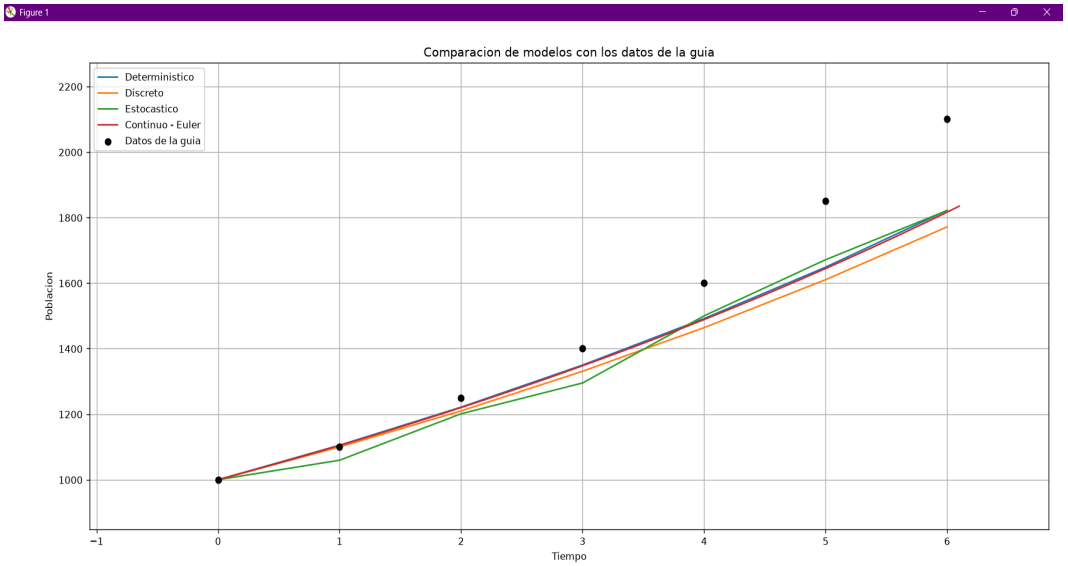
5. Resultados esperados:

Al finalizar el estudiante entregará:

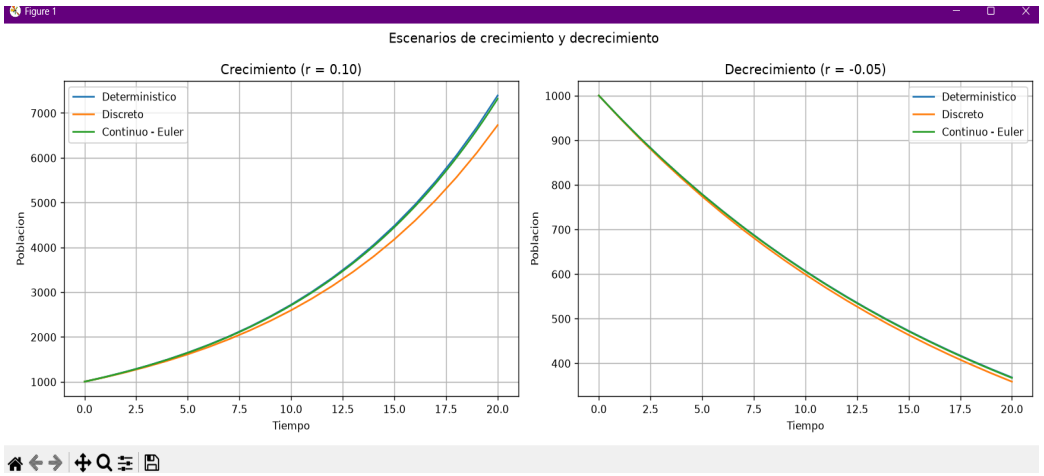
- **Modelo implementado correctamente.**



- **Gráficas de crecimiento y decrecimiento.**



- 

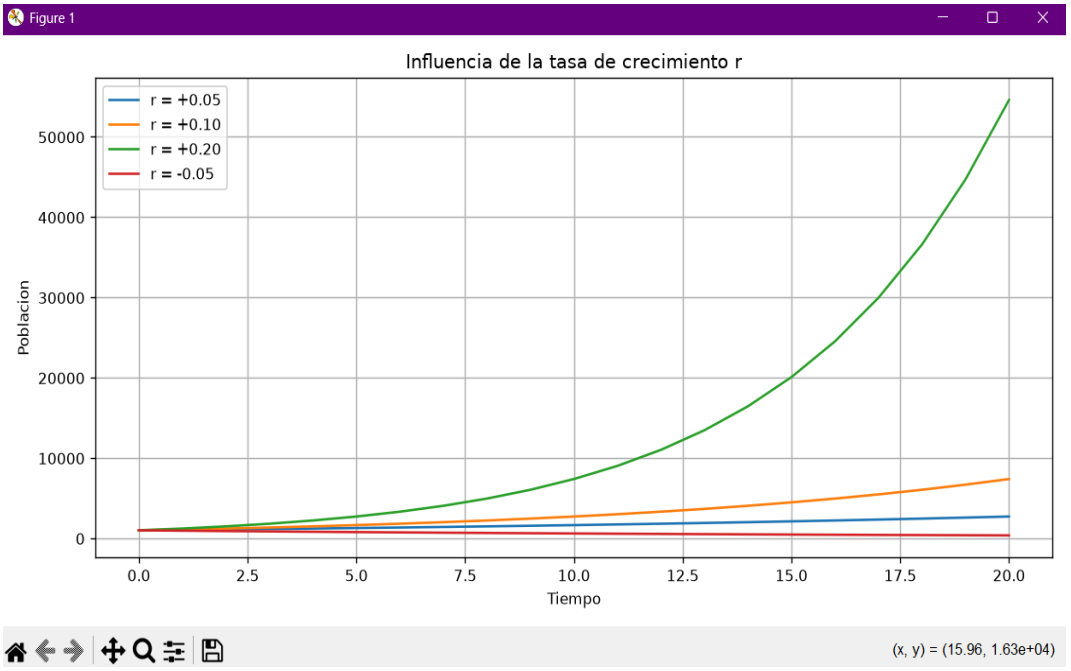


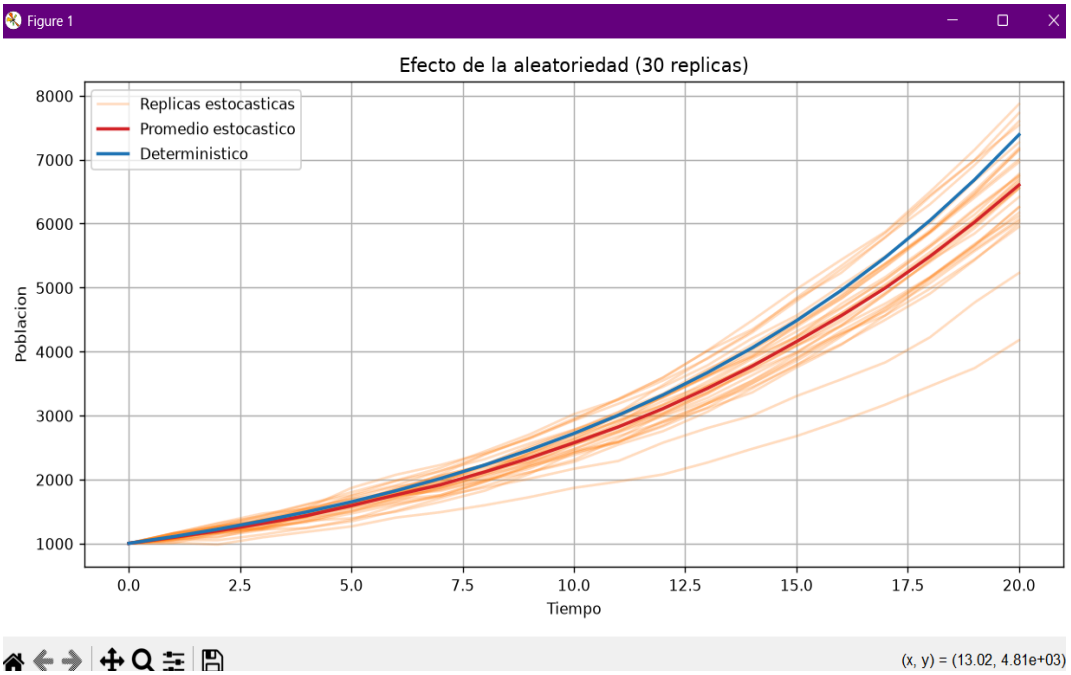
-

- **Identificación de la influencia de r.**

  La tasa r actúa como un factor de escala de la velocidad de cambio del sistema.

  Pequeñas variaciones en r (por ejemplo, pasar de $r = 0.10$ a $r = 0.15$) provocan marcadas divergencias exponenciales en el largo plazo, demostrando la alta sensibilidad del modelo a los parámetros de entrada.





- **Interpretación matemática del comportamiento**
  Determinístico vs. Estocástico: El modelo determinístico produce la misma trayectoria ante condiciones iniciales fijas. El estocástico introduce dispersión e incertidumbre alrededor de la tendencia media determinista.
  Discreto vs. Continuo: El modelo discreto evalúa cambios en saltos fijos de tiempo $\Delta t = 1$. El modelo continuo (mediante Euler) converge hacia la solución analítica diferencial exacta a medida que $\Delta t \to 0$.

6. Preguntas de Control:

1. **¿Qué representa el arreglo de entrada?**
   Representa la serie histórica o datos empíricos observados del sistema real en instantes discretos de tiempo ($t_0, t_1, \dots, t_n$), sirviendo como patrón de referencia para validar la precisión de las simulaciones.
2. **¿Cuál es la diferencia entre un modelo determinístico y uno estocástico?**
   El modelo determinístico produce siempre exactamente la misma salida ante iguales condiciones de entrada. El estocástico incorpora componentes aleatorios (ϵ_t), generando

salidas variables y distribuciones de probabilidad entre corridas.

3. **¿Qué efecto produce modificar la tasa (r)?**
   Altera la velocidad y dirección del cambio poblacional: si $r > 0$ el sistema crece exponencialmente; si $r = 0$ la población se mantiene constante ($P(t) = P_0$); y si $r < 0$ el sistema sufre decaimiento exponencial.
4. **¿Qué representa el parámetro (σ)?**
   Representa la desviación estándar de la variable aleatoria de ruido ($\epsilon_t \sim N(0, \sigma^2)$), midiendo la magnitud de las fluctuaciones impredecibles o pertubaciones ambientales externas.
5. **¿Qué ocurre cuando aumenta el nivel de ruido?**
   Incrementa la variabilidad y dispersión de los resultados simulatedos con respecto a la tendencia central determinista, pudiendo provocar eventos extremos como la extinción prematura de la población ($P \leq 0$).
6. **¿Cuál es la diferencia entre los modelos discreto y continuo?**
   El modelo discreto actualiza las variables en pasos de tiempo fijos y separados ($t, t+1, t+2$) mediante ecuaciones en diferencias. El modelo continuo asume que los cambios ocurren de forma ininterrumpida en todo instante mediante ecuaciones diferenciales ($\frac{dP}{dt}$).
7. **¿Qué función cumple (dt)?**
   Es el tamaño del paso de integración temporal en la aproximación numérica de Euler. Determina la resolución de la simulación: cuanto menor sea dt, mayor será la precisión y menor el error numérico acumulado.
8. **¿Por qué es importante visualizar los resultados mediante gráficas?**
   Permite comparar visualmente y de forma inmediata múltiples series temporales, detectar patrones emergentes, calibrar parámetros y evaluar la desviación entre modelos continuos, discretos y estocásticos.
9. **¿Qué modelo presenta comportamiento aleatorio?**
   El **Modelo Estocástico**, debido a la incorporación del término de ruido no determinista ϵ_t derivado de una distribución de probabilidad normal.
10. **¿Cómo cambia la simulación cuando se introduce un nuevo arreglo de datos?**
    Cambian la condición inicial P_0 y el horizonte de tiempo, exigiendo un proceso de recalibración de la tasa de crecimiento r y de la varianza σ para adaptar las curvas de los cuatro modelos al nuevo comportamiento empírico observacional.

7. Conclusiones

Convergencia del Método de Euler: La aproximación continua numérica por el método de Euler demostró converger de forma precisa hacia la solución analítica determinista exponencial conforme el paso temporal Δt se mantiene en valores pequeños ($\Delta t \leq 0.1$).

Impacto de la Estocasticidad: La inclusión de ruido gaussiano $\epsilon_t \sim N(0, \sigma^2)$ refleja con mayor fidelidad la variabilidad y las fluctuaciones ambientales de un sistema real en comparación con las trayectorias suaves de los modelos deterministas.

Versatilidad Computacional: Python resultó ser un entorno robusto y eficiente para implementar de forma concurrente modelos continuos, discretos y estocásticos, permitiendo validar numéricamente la teoría mediante visualizaciones gráficas comparativas.

8. Declaración de uso de IA

En este proyecto se hizo uso de la Inteligencia Artificial para la elaboración del código en Python, se uso la herramienta opencode usando un prompt maestro que seguía instrucciones basadas en un análisis realizado a través de los tres primeros pasos de un proyecto de simulación.

Prompt usado:

PROMPT MAESTRO DE INSTRUCCIÓN A LA IA:

Actúa como un experto en Simulación Computacional y Modelado Matemático en Python.

Necesito que me ayudes a desarrollar el script de código para comparar cuatro paradigmas de simulación poblacional aplicados a un arreglo de datos empíricos.

CONTEXTO Y PARÁMETROS DEL SISTEMA (PASOS 1-3 DE SIMULACIÓN):
- Arreglo de Datos Reales: [1000, 1100, 1250, 1400, 1600, 1850, 2100]
- Población Inicial (P0): 1000
- Pasos de tiempo (T): 0 a 6
- Tasa de crecimiento (r): 0.125
- Desviación estándar del ruido estocástico (sigma): 25.0
- Paso numérico de Euler (dt): 0.1

REQUERIMIENTOS DEL CÓDIGO EN PYTHON:
1. Modelo Determinístico: Implementa P(t) = P0 * exp(r * t).
2. Modelo Discreto: Implementa P_{t+1} = P_t + r * P_t.
3. Modelo Estocástico: Implementa P_{t+1} = P_t + r * P_t + ruido, con ruido ~ Normal(0, sigma) y control para evitar poblaciones negativas.
4. Modelo Continuo por Euler: Implementa P_{t+dt} = P_t + dt * (r * P_t).
5. Visualización: Genera una figura con Matplotlib que superponga las 5 curvas (Datos reales, Determinístico, Discreto, Estocástico y Continuo Euler), incluyendo leyendas claras, etiquetas de ejes, título y cuadrícula.

Entrega código limpio, completamente funcional, comentado en español y libre de errores.

9. Bibliografía

[1] J. S. Smith and D. T. Sturrock, Simio and Simulation: Modeling, Analysis, Applications. Simio LLC, 2024. [En línea]. Disponible: Recurso web (ISBN: 978-1-938207-06-8).

[2] J. R. Baxter, Introduction to Probability. University of Minnesota, 2025. [En línea].

[3] R. Salomone, L. F. South, C. Drovandi, D. P. Kroese, and A. M. Johansen, *Unbiased and Consistent Nested Sampling via Sequential Monte Carlo*. The Royal Statistical Society / Oxford University Press, 2025. [En línea].

[4] D. P. Kroese and Z. I. Botev, *An Advanced Course in Probability and Stochastic Processes*. The University of Queensland, 2025. [En línea].

[5] S. Moka, C. Hirsch, V. Schmidt, and D. Kroese, "Efficient Rare-Event Simulation for Random Geometric Graphs via Importance Sampling," Ithaca, EE. UU., 2025. [En línea].

10. Anexos

- **Link de repositorio de Github:**
  https://github.com/BrTrl3/RepositorioSimulacion-BryanTroya.git